

뉴스 헤드라인에 주가 방향 예측 신호는 존재하는가?

딥러닝·고전 ML·규칙 기반 모델의 방향 예측력 비교 검증

12210511 한명일 항공우주공학과 선택과제 (A 형)

요약: BIGKinds에서 제공하는 2021~2025년 한국 경제·국제 뉴스 헤드라인으로 KOSPI·KOSDAQ 지수와 삼성전자(단일종목)의 주가 방향을 horizon $h \in \{1, 5, 21, 252\}$ 거래일에 대해 예측했다. 단일 NVIDIA RTX 4090(24GB)에서 수 일에 걸쳐 24개 통제 실험(EXP-A~X)을 수행하며, 매 실험의 결과를 분석하여 다음 실험을 설계하는 과정을 반복했다. 핵심 성과는 두 가지다. 첫째, 평가 지표(metric)를 바꾸자 결론이 뒤집혔다 — 3-class macro-F1로는 가려졌던 약한 양(+)의 방향 신호가 IC(Information Coefficient, 정보 계수)로 드러났다(RoBERTa KOSPI h5 IC $\approx +0.15$, 6시드 안정). 둘째, 삼성전자 단일 종목 전체 헤드라인 학습 모델은 정상기(2024, 일명 ‘박스피’)에서 방향 적중률 0.59로 무작위(0.50)를 상회하는 약한 방향 신호를 보였다(하락 우세장을 가정하고 ‘항상 하락’과 비교 시 0.57을 근소하게 상회). 이러한 정량적 주가 예측 성능 지표 및 모델 외에도 본 보고서는 실험 및 학습 과정에서 보인 AI 모델의 낮은 성능의 원인을 모델 자체에 국한하지 않고 데이터 규모로 규명하며 연구 과정의 체계성과 엄밀함을 보였다는 점에서도 의의가 있다. 또한, 다음 github repo에 모든 코드 및 데이터셋을 공개하여 전 실험 과정이 재현 가능하다: <https://github.com/OnePersonOne1/StockNewsPredictor>

1. 서론

1.1 문제 정의와 연구 질문

필자는 성인이 된 2021년부터 주식 투자를 시작하였다. 항공우주공학을 전공하지만 본교 금융투자학과에 개설된 전공선택 과목 <20대를 위한 증권투자론> [13]을 수강하는 등 주식 및 경제 전반에 대한 관심과 흥미가 매우 크다. 현재는 UNIST Vision & Learning Lab에서 외부참여연구원(인턴)으로 피지컬 AI 및 VLM(Vision-Language Model)에 대해 연구를 진행하고 있다. 이에 언어 모델(Language model)을 활용한 주가 예측 모델을 개발하는 것을 본 보고서의 주제로 선정하였다. 2024-1·2024-2 우수 레포트집에도 주가 예측을 다룬 보고서가 다수 있었으나, 대부분 가격 수준 자체를 회귀(regression)로 예측하거나 기술적 지표(technical indicator)·재무제표를 입력으로 삼았고, 뉴스를 활용한 보고서는 주제 분류(topic classification)나 감성 분석(sentiment analysis)에 머물렀다. 본 보고서는 그 둘을 결합하여 오직 뉴스 헤드라인(news headline)만으로 주가의 방향을 예측하고, 나아가 미래 정보 누설(look-ahead bias) 봉쇄와 평가 지표(metric) 선택이 결론을 어떻게 뒤집는지를 24개 통제 실험으로 규명한다는 점에서 기존 보고서들과 차별화된다.

최근 들어 국내 증시는 역사상 유례없는 상승을 맞이하고 있다. 이에 국내 주식 시장에 대한 관심이 급증하고 있다. 기사에 따르면 2026년 기준 “상장사 주주 1456만명으로 사상 최대”라고 한다 [12]. 이러한 대부분의 개인 투자자들은 기업 내부 소식망이나 블룸버그와 같은 정보 전달 업체에 접근할 수단이 부족하므로 주로 뉴스에 의존하여 주식 거래를 하는 경향이 있다. 일명 ‘개미’로 불리는 개인투자자들은 정보와 결집력이 부족하기 때문에 기관과 외국인의 매도/매수세에 휘둘리곤 한다. 이 ‘개미’들이 뉴스를 통해 접하는 소식은 이미 오래전에 증권가에서 암암리에 돌던 소문들인 경우가 허다하지만, 그럼에도 불구하고 필자를 포함한 ‘개미’들은 정보의 출처가 뉴스로 한정되기 때문에 울며 겨자 먹기로 매번 ‘뉴스’에 팔고, ‘뉴스’에 사는 수밖에 없다. 그리고 그 결과, 안타깝게도 “비쌀 때 사고, 쌀 때 파는” 경우가 종종 벌어지고 있다. 여기서 우리 개미는 투자를 위한 당연한 물음을 던질 수밖에 없다. “과연 뉴스를 보고 투자하는 것이 정말 효과적일까?” 그리고 “효과가 있다면 얼마나 있을까?” 효율적 시장 가설(efficient market hypothesis) [7]의 weak-

form은 이미 공개된 과거 정보로 초과수익을 얻을 수 없다고 본다. 이에 본 프로젝트는 공개 뉴스 헤드라인(news headline)만으로 주가 방향을 예측하는 신호가 정말로 존재하는지를, 존재한다면 그 영향이 어느 정도인지, 뉴스 정보를 투자에 활용하는 것이 올바른지 국내 주식 시장에 한정하여 정량적 및 정성적으로 분석하였다.

본 보고서의 결론을 요약하자면 다음과 같다: “뉴스를 토대로 단기적인 상승/하락 신호를 어느정도 파악할 수는 있지만, 이를 장기투자에 참고하기에는 부적절하다.” 일명 ‘선반영’, 즉, 모두가 아는 정보는 영향이 크지 않다는 원론적인 얘기에 본 보고서는 도달하였다. 그러나 본 보고서의 진정한 의미는 설계한 모델이 주가를 잘 예측하여 “좋은 점수”를 얻는 것뿐만 아니라, “어떻게 측정하면 무엇이 보이는가, 그리고 이를 어떻게 해석할 것인가”를 24개 통제 실험을 통해 끝까지 따져본 탐구 과정 자체 및 해석에도 존재한다.

학부생이 보기에는 전문 용어와 사전 지식이 많이 필요할 것으로 예측되므로 최대한 관련 논문을 제시하고 풀어서 보고서를 작성하였다. 또한, 모든 코드·로그·산출물은 요약에 명시된 github repo에 공개하여 재현 가능하다.

1.2 접근 방식의 타당성

금융 시계열은 신호 대 잡음비(signal-to-noise ratio)가 극히 낮고(즉, 어떤 한 종목에 호재가 있어도 전쟁, 금리 인상 등 다른 여러 외부 요인에 의해서 주가가 결정되므로, 그 호재 하나로 주가 방향성을 예측하기 어렵다), look-ahead bias(미래 정보 누설: 과거를 통해 미래를 예측하는 모델을 만드는데, 미래 데이터가 학습 데이터에 주어지면 정답지를 보고 시험을 치는 것과 같은 꼴이다)에 취약하다. 따라서 본 연구에서 다음과 같은 모델을 설계했다.

(가) ML 학습 시 흔히 사용되는 데이터셋 무작위 셔플 대신 temporal split(시간 순 분할)을 강제하고,

(나) 뉴스일과 거래일을 엄격히 매핑해 미래 정보 누설을 봉쇄하며,

(다) 라벨 임계 추정을 train 구간으로만 한정했다.

(라) 또한, 딥러닝(RoBERTa) 모델 외에도 비-ML 기법인 lexicon(즉, wordcount, 단순 단어 세기 기법)과 고전적인 ML 알고리즘인 TF-IDF + Logistic Regression(로지스틱 회귀), 무작위 기법(이론적 확률)을 비교군으로 설정하여 동일 조건에서 딥러닝 모델과 비교했다.

본문에 등장하는 다소 생소한 주식, 통계, 그리고 성능 지표 용어와 학습 모델(macro-F1, IC, 룬샷 백테스트, RoBERTa, TF-IDF 등)에 관한 보다 자세한 설명은 부록(Appendix)에 정리했다.

2. 본론

2.1 데이터 (필수 요소 ①): 데이터 요약표

헤드라인은 ‘한국언론진흥재단’이 제공하는 뉴스 빅데이터 서비스 BIGKinds [11](빅카인즈)에서 한국경제·조선일보·한겨레의 경제·국제 기사 제목을 .csv 형식으로 다운로드했다. 이때 자료 열람을 위해서 회원가입이 필요하다. 회원가입 후 홈페이지에서 ‘상세검색’에 들어가면 step 1~3에서 기간, 신문사, 카테고리 등을 설정할 수 있다. 이후 검색하면 조건에 맞는 데이터를 수집할 수 있다. 이때 자료 다운로드 회당 기사 2만 건 제한이 있으므로, 자료 수집 기간을 적절히 분할하여 다운로드해야 한다. 이때 뉴스 헤드라인 제목은 저작권 콘텐츠이지만 학술 비영리 재현 목적으로 사용 가능성을 확인했다.

주식 가격은 공개된 파이썬 패키지인 FinanceDataReader [9]를 통해 수집했다. KOSPI(KS11)·KOSDAQ(KQ11) 지수와 삼성전자(005930) 일일 종가 데이터를 수집했고, 수집한 데이터

가 한국거래소(KRX) 종가와 일치함을 확인했다. 수집한 데이터의 규모와 출처를 정리하면 다음 표 1과 같다. 수집한 데이터는 모두 github repo에서 data/에 정리 및 저장해 두었다.

항목	출처	구성 / 규모	용도
본체 헤드라인	BIGKinds	경제·국제 제목, 2021~2024 (2024 단독 104,920건, 일평균 ~287)	지수 예측 모델 입력
IT 섹션	BIGKinds	IT·과학 + 반도체 섹션 별도 export	섹터 신호 검증(EXP-L/N)
삼성전자 단독	BIGKinds	종목 검색식, 2021~2025 (24,357 건, 일평균 ~13)	단일종목 실험 (EXP-V/W/X)
가격 시계열	FinanceDataReader	KS11·KQ11·005930 종가, 2021~2026.6	forward return·라벨 산출

표 1. 데이터 요약표.

초기 학습 및 실험 시에 라벨은 forward return r_h 에 3-class ternary(삼진) $\{-1, 0, +1\}$ 을 부여한다. 임계값 $\varepsilon_h = 0.3 \cdot \sigma_h$ 이며, σ_h 는 해당 train 구간 수익률 표준편차로만 추정해 val·test에 적용한다. 이를 통해 미래 누설 방지를 철저히 했다. 2024 단일연도(single year) 학습 기준 train/valid/test 데이터셋을 분할한 기준은 지수당 244행 → temporal split으로, train 406 / val 42 / test 40이었다. 다중연도(multiyear)는 train 1,358(2021~2023년 9월) / val 120(2023년 10월~12월) / test(2024 전체) 488행이다. 자세한 라벨·지표 정의는 부록 A·D를 참조하면 된다.

이름	관련 실험	대상	train	val	test	합계
y2024	EXP-A~C	지수 (KOSPI+KOSDAQ)	406	42	40	488
multiyear	EXP-D~T	지수 (KOSPI+KOSDAQ)	1,358	120	488	1,966
samsung	EXP-V/W	삼성전자	739	244	242	1,225
samsung_cv	EXP-X	삼성전자	494	245	486	1,225

표 2. 분석 단위 데이터셋 — 프로필별 학습/평가 행수 (1행 = 거래일 × 지수). 시간 순 분할 경계: y2024 = train 2024-01~10 / val 11 / test 12; multiyear = train 2021-01~2023-09 / val 2023-10~12 / test 2024 전체; samsung = train 2021~23 / val 2024 / test 2025; samsung_cv = train 2021~22 / val 2023 / test 2024+2025.

날짜	시가	고가	저가	종가	거래량	거래대금	시총
2024-01-03	2643.54	2643.72	2607.31	2607.31	4.63E+08	1.01E+13	2.1E+15
2024-01-04	2592.44	2602.64	2580.09	2587.02	7.7E+08	8.99E+12	2.08E+15
2024-01-05	2586.89	2592.29	2572.6	2578.08	5.22E+08	8.38E+12	2.08E+15
...	...	...	...	...	...	...	...

표 3. KOSPI 데이터 예시(한국거래소 제공)

일자	언론사	기고자	제목
20240229	조선일보	박유연	“남 얘기가 아네요. 금리 하락이 앞으로 내 재산에 가져올 변화”
20240229	한국경제	류병화	이지스, 트리아논 스탠드스틸 3개월 연장 EOD 다시 유예
20240229	한국경제	최석철	실적 꺾였는데 오상헬스케어, 공모가 33% 올린 2만원 확정
20240229	한국경제	박동휘	[차장 칼럼] 수출로 먹고사는 한국의 해운업 홀대
...	...	...	...

표 4. 뉴스 데이터 예시(BIGKinds 제공)

2.2 분석 절차 개요

전체 파이프라인은 크게 그림 1과 같다. 수집 → 거래일 매핑(누설 봉쇄) → forward return·라벨링 → temporal split → 세 가지 method(렉시콘 / TF-IDF / RoBERTa) 학습·예측 → 두 지표(macro-F1 / 방향·IC·백테스트) 산출 및 평가 → 해석의 순서이다.




그림 1. 데이터 분석 파이프라인 순서도. 두 데이터 소스에서 출발해 누설 봉쇄·라벨링·시간 순 분할을 거쳐 세 방법으로 학습하고 두 갈래 지표로 해석한다.

2.3 방법론: 미래 정보 누설 봉쇄와 라벨 설계

시계열 예측에서는 미래 정보의 누설이 발생하면 안 된다. 모델이 미래 정보를 학습해버리면 정답

지를 보고 미래를 예측하는 것과 같기 때문이다. 이를 막기 위해 뉴스일 D를 “D 이후 첫 거래일 T ($T > D$, 업격 부등호)” 관계로 매핑한다. 즉, 거래일 T의 증가로 측정을 시작하되 입력 헤드라인은 T 장 시작 이전 발행분만 사용한다.

```
# phase1/build_dataset.py — 뉴스일 D를 '다음 거래일' T( $T > D$ )로 매핑
td = np.sort(trading_days.astype('datetime64[ns]'))
idx = np.searchsorted(td, nd, side='right') # side='right' →  $T > D$  보장
out['trading_day'] = td[idx[idx < len(td)]] # 마지막 거래일 이후 뉴스는 폐기
for h in HORIZONS: # forward return ( $h \in \{1, 5, 21, 252\}$ )
    g[fret_h{h}] = g['close'].shift(-h) / g['close'] - 1.0
```

코드 1. look-ahead 봉쇄(searchsorted side='right')와 forward return 계산.

2.4 핵심 모델: learnable query attention pooling

하루에 수백 건의 헤드라인이 쏟아지므로 핵심 설계 과제는 “가변 개수의 헤드라인을 하루 한 개의 벡터로 어떻게 요약하는가”이다. 가장 간단하고 구현이 쉬운 단순 평균(mean pooling)은 중요한 정보를 잡음에 묻는다. 이에 본 연구는 학계에서 통용되는 learnable query attention pooling을 적용했다 [1], [4]. 이를 통해 attention map으로 어떤 정보가 가장 중요했는지 확인할 수도 있다. 수식에 사용된 기호 정의는 표 5, 연산은 수식 1과 같다.

기호 (notation)	정의
h	예측 horizon(거래일 수), $h \in \{1, 5, 21, 252\}$
$e_i \in \mathbb{R}^d$	i 번째 헤드라인의 [CLS] 임베딩 ($d = \text{hidden size} = 768$)
$q \in \mathbb{R}^d$	학습 가능한 단일 질의(learnable query) 벡터; 모든 horizon 공유
α_i	i 번째 헤드라인의 attention 가중치, $\sum_i \alpha_i = 1$
$d_t \in \mathbb{R}^d$	거래일 t 의 요약 벡터(daily vector)
W_h, b_h	horizon h 의 분류 head 파라미터 (multi-task head)
$\hat{y}^h$	horizon h 의 예측 확률분포

표 5. 모델 수식 기호의 notation 정의.

- (1) $e_i = \text{Encoder}(\text{headline}_i)[\text{CLS}] \in \mathbb{R}^d$
- (2) $\alpha_i = \text{softmax}_i(q \cdot e_i)$ (패딩 헤드라인은 $-\text{inf}$ 로 제외)
- (3) $d_t = \sum_i \alpha_i \cdot e_i$ (+ index_emb) # attention pooling
- (4) $\hat{y}^h = \text{softmax}(W_h \cdot d_t + b_h)$ for $h \in \{1, 5, 21, 252\}$

수식 1. 단일 질의 어텐션 풀링과 multi-task horizon head. $q \cdot e_i$ 는 내적(dot product).

즉, 쿼리 q 와 헤드라인 임베딩 e_i 의 내적이 클수록 큰 가중치 α_i 를 받는다 — 다시 말해 모델이 “그날 중요한 헤드라인”을 스스로 학습한다. 그래서 learnable query 방식인 것이다. 인코더(encoder)는 한국어 사전학습 모델 klue/roberta-base [3](RoBERTa, 구조는 [2])를 full fine-tuning(사전 학습 모델 가중치 전체 미세조정: 학습 환경의 한계로 인해 완전히 처음부터 학습하기는 불가능하고, 기업이나 기관에서 학습시킨 모델을 우리 환경에 맞게 미세조정 하는 것이다.)했고, HuggingFace Transformers [10]로 구현했다. 가중치 α_i 는 horizon 공통이라 attention map만으로 학습 성공 여부를 정성적으로 진단할 수 있는데(2.7절 EXP-D), 이러한 정성적 평가를 통해 모델의 개선 방향을 결정하였다. 또한, 의도적으로 더 큰 모델은 쓰지 않았다 — 후술하듯, 분석 결과 성능 저하는 모델 크기가 아니라 데이터 규모라 판단했기 때문이다.

2.5 Baseline와 평가 지표

세 가지 baseline과 AI 기반 학습 모델의 비교를 진행한다. ① random(이론 macro-F1 = 1/3, 즉, 상승-보합-하락의 이론적 확률값), ② 비-ML 렉시콘(단순 단어 개수 세기) [5], ③ 고전 ML: TF-IDF + Logistic Regression(min_df=2, max_features=20000, class_weight=balanced) [6]. 평가 지표는 두 갈래다: 분류 정확도 계열의 macro-F1(3-class, 즉, 상승-횡보-하락으로 나누어 평가)과, 방향성 계열의 이진 방향 정확도(즉, 상승-하락만 평가) · IC(Spearman 순위상관: 상승 폭의 크기가 아니라, 모델이 높게 본 날과 실제로 많이 오른 날의 순위가 일치하는지를 평가함. 이렇게 계산한 IC는 금융에서 보편적으로 쓰이는 예측력 지표임) · 룡샷 백테스트(알고리즘 실제 과거 주식 대입 시뮬레이션)이다. 각 지표의 정의·기준선·해석은 부록 A~C에 상세히 설명한다. 기본적인 공통 하이퍼파라미터는 AdamW(lr 2e-5, weight decay 0.01, warmup 0.1, grad-clip 1.0), best-val 체크포인트, MAX_HEADLINES=30(최신순 top-30), MAX_LENGTH=64이며, 실험별 변형은 § 2.6 표 6에 정리했다.

2.6 실험 환경과 종합 실험표

#	EXP	실험 내용 · 의도	프로필 / 조건	b/ep/mh	시드	핵심 결과
1	A	RoBERTa 주 모델 · 첫 baseline 대결	y2024 / all	16/4/30	42	단일클래스 붕괴, AI 모델 < TF-IDF
2	B	encoder freeze + 헤드라인 확대로 붕괴 완화 시도	y2024 / freeze	32/30/100	42	AI 모델 val ↑ (0.25→0.31)
3	C	관련성 필터(증권/거시) 강화로 잡음 제거	y2024 × market·macro	16/4/30	42	TF-IDF 대폭 ↑ (KOSDAQ h5 0.25→0.45)
4	D	학습량 3배(다년)로 성능 붕괴 해소	multiyear / all	16/4/30	42	붕괴 해소 (attention lift 1.07×→7.85×)
5	E	다년 × 관련성 필터 결합	multiyear × market·macro	16/4/30	42	데이터셋 필터 적용 시 성능 상승 (KOSPI h1 0.380)
6	F	데이터 크기 vs 2025 특수성 분리 통제	y2021 · y2022 · y2023	16/4/30	42	정상기(train23/test 24)도 성능 붕괴→데이터 크기 문제
7	G	IT/반도체 섹터 비중 효과 점검	multiyear × it·market_it	16/4/30	42,0-2	IT 9%가 전체급 신호: 한국 시장 반도체 비중 50%
8	H	평가 지표 전환: 이진 · IC · 백테스트	multiyear (6시드)	16/4/30	42,0-4	macro-F1이 가린 약신호를 IC로 검출
9	I	신호의 출처 해석 (확신도 · attention)	multiyear (추론)	-	42	고 confidence 적중 67%, 어닝·매크로·금리 키워드 주목
10	J	고 confidence 구간 정량화	multiyear (추론)	-	42	고 confidence 이진acc 0.54→0.66, IC 0.18→0.21
11	K	제목+본문 입력 효과	multiyear / body(len128)	4/4/30	42	개선 없음 (IC 0.18→0.09) — 신호는 대부분 제목에서
12	L	IT_section 병합 보강	multiyear + IT	16/4/30	42	TF-IDF 성능 유지, RoBERTa 성능 불

#	EXP	실험 내용 · 의도	프로필 / 조건	b/ep/mh	시드	핵심 결과
						안정
13	M	전 실험(H) 이진/IC 다중시드 재평가	y2024 · y2022 · multiyear	16/4/30	0-4	원인=데이터 크기 확정 (소표본 IC $\pm 0.1 \sim 0.3$)
14	N	IT_section 단독 코퍼스	multiyear / IT-only	16/4/30	42,0-4	IT 단독 약함 (IC +0.035 vs 본체 +0.146)
15	O	data/ 전체 비여과 결합	multiyear / combined	16/4/30	42,0,1	RoBERTa는 본체와 동일 (top-30 절단)
16	P	MAX_HEADLINES 확대 (공정성 점검)	multiyear / grad_ckpt	8/4/100·200	42	더 넣으면 RoBERTa ↓ (0.298→0.181)
17	Q	top-30 최신순 vs 랜덤	multiyear / random	16/4/30	42,0-4	최신순 우위 (IC +0.146 vs +0.028)
18	R	공정 비교 (전부 top-30, 3cls+이진)	TF-IDF · wordcount	-	-	동일 입력서도 지표별 성능 차이 유지
19	S	실제 시각(타임스탬프) 정렬	multiyear / time	16/4/30	42,0-4	시각순 $\geq$ 날짜순 > 랜덤 (단기 개선)
20	T	4 epoch 충분성 점검	multiyear (+2024)	16/10/30	42	기존 학습 epoch 부족 확인(Train loss 추가 하락 여지)
21	V	삼성전자 단일종목 전체 학습	samsung / time	8/30/64	42	단기 방향(h5) 적중률 0.59
22	W	2025 시장 예외성 분석	samsung (추론)	-	42	2025 +124% 역사상 유례없는 폭등장 → 성능 하락
23	X	2024 완전 held-out 재검증	samsung_cv / time	8/30/64	42	역사상 유례없는 폭등 기간 성능 하락 관측
24	U	전체 헤드라인 × 이진 × 30ep (최종)	multiyear / time / bin	2/30/1059	42	미진행(학습 환경 및 시간상 학습 불가능할 것으로 판단 - 결과 미포함)


표 6. 24개 실험의 학습 조건·시드·학습시간·핵심 결과 (수행 시각 순). 노랑=방법론 전환점(D·H·T), 초록=가장 명확한 양(+)의 결과(V). b/ep/mh = batch / epochs / MAX_HEADLINES.

2.7 실험 연대기: 실패·진단·재설계의 반복

모든 학습은 단일 NVIDIA RTX 4090 (24GB), Linux, CUDA 환경에서 수행했다. 이 절은 표 6의 실험을 시간 순으로 따라가며, 각 실험의 동기(원인) → 결과 → 분석 → 다음 실험의 설계(대안) 흐름이 어떻게 이어졌는지 서술한다.

2.7.1 첫 결과 — 딥러닝이 진다 (EXP-A)

- 첫 실험 EXP-A 은 가장 단순한 가설에서 출발했다: “강력한 사전학습 언어모델 RoBERTa 를 미세조정하면 단어 단순 알고리즘 baseline 쯤은 쉽게 이길 것이다.” 그러나 2024 년 단일연도 데이터(train 406 행)로 학습한 RoBERTa 는 test 예측을 한 클래스로 쏟아내는 단일클래스 붕괴(single-class collapse: 모델이 그날 뉴스 내용을 보지도 않고 매번 똑같은 답("다 상승")만 찍어 버리는 상태. 마치 시험에서 모든 문제에 무조건 "3 번"만 적어내는 학생과 같다. 본 과제는 상승·횡보·하락 세 갈래를 맞히는 데다 채점 방식(macro-F1)이 세 갈래를 골고루 못 맞히면 점수를 깎기 때문에, 이렇게 한 답만 적으면 점수가 무작위로 찍는 수준(0.333)보다도 낮아진다.)를 일으켰고, macro-F1 은 KOSPI h1 기준 0.111 로 무작위(0.333)는 물론 TF-IDF(0.279)에도 크게 못 미쳤다.
- 분석: train 라벨은 거의 균형(137/136/133)이었으므로 붕괴는 클래스 불균형 탓이 아니었다. Attention map(그림 2, 3) 확인 결과 attention 가중치마저 균일(mean pooling 으로 퇴화)해진 점이 단서였다.
- 대안: 분석으로부터 두 갈래 가설이 나왔다: (가) 인코더 과적합 문제인지, (나) 데이터 양 또는 품질이 부족한지. 이를 차례로 검증하기로 했다.



Attention map — 헤드라인별 가중치 (가장 집중된 test 사례)





그림 2, 3. 초기 실험 attention map: 초기 실험에서는 가중치가 특정 헤드라인에 집중되지 못하고 거의 균일하게 분포하고 있다.

정렬된 attention 가중치 (균일=1/n≈0.016)






그림 4, 5: 후기 실험 attention map: 후기 실험에서는 특정 경제 키워드에 모델이 강하게 반응하고 있음을 확인할 수 있다.

2.7.2 성능 붕괴의 원인을 추적하다 (EXP-B~G)

- EXP-B는 EXP-A의 가설 (가)를 거론했다. 인코더를 동결(freeze)하고 학습에 사용할 일일 헤드라인 수를 100개로 늘려 classification head만 학습하자 딥러닝 모델의 val macro-F1이 0.25→0.31로 부분 회복됐으나 test는 여전히 TF-IDF에 못 미쳤다. 인코더 freeze가 성능을 부분적으로 상승시켰으나 여전히 성능이 기대 이하인 점을 고려했을 때 문제의 본질이 인코더 자체보다 학습 데이터셋 양에 있음을 염두에 두고 이후 추가 실험을 진행했다.
- EXP-C는 데이터 품질을 의심하고 필터 적용 실험을 진행했다. BIGKinds에서 제공한 데이터들은 태그가 무분별하게 달려있는 기사, 카테고리과 전혀 상관없는 기사들이 일부 있었다. 이러한 입력 잡음이 모델 성능에 미치는 영향을 염두하고 증관-거시 카테고리만 남기는 관련성 필터를 데이터셋에 적용해 전처리했다. 흥미롭게도 TF-IDF는 크게 향상(KOSDAQ h5 0.25→0.45)되어 무작위 확률(0.33)을 상회했지만 RoBERTa의 성능은 거의 변하지 않았다. 두 모델이 데이터셋 정제에 정반대로 반응한다는 흥미로운 현상은 추후 실험(EXP-E)에서 분석했다.
- EXP-D에서 데이터셋을 늘려서 가설 (나)를 정면으로 검증했다 — 2021~2023년 3년치(train 1,358행)로 학습량을 3배 늘리자 붕괴가 해소됐다. attention 집중도(top-1 lift)가 1.07×에서 7.85×로 치솟아 모델이 비로소 “중요한 헤드라인”을 고르기 시작했고, 예측도 세 클래스로 고르게 분산됐다. 다만 macro-F1 지표상 모든 방법이 무작위 부근이라 신호 자체는 여전히 약하다고 볼 수 있다. (그림 6).




그림 6. 방법론별 horizon 예측력 (macro-F1; 다중연도, test=2024). 붕괴는 해소됐으나 macro-F1 상으로는 모든 방법이 무작위선(점선) 부근.

- EXP-E 는 앞선 C 와 D 의 실험 결과를 결합해 “데이터도 늘리고 필터도 걸면 성능이 상승하지 않을까?”이란 가설에 대해 검증했다. 이 경우 필터+TF-IDF 조합이 KOSPI h1 0.380 으로 가장 강했으나, RoBERTa 에는 필터가 앞선 C 의 결과와 마찬가지로 이득이 없었고, market 필터는 오히려 헤드라인 수를 줄여 해로웠다. 여기서 “TF-IDF 는 데이터셋 정제 및 전처리를, RoBERTa 는 데이터셋 볼륨을 선호한다”는 결론을 내릴 수 있었다. 이는 통계 기반 알고리즘인 TF-IDF 은 그 통계에 속한 자료의 품질이 높을수록 성능이 상승함을 보이고, 데이터 자체를 학습하는 RoBERTa 와 같은 언어모델은 스스로 그 데이터의 중요도를 학습하기에 이러한 차이점을 보이는 것으로 해석할 수 있다.
- EXP-F 는 “2024 년 학습 모델의 붕괴가 혹시 역사적으로 유례없는 강한 상승을 보인 2025 년 주식 시장의 특수성에 의한 것이 아닌가?”를 배제하기 위해 다른 조건을 통제하고 학습 년도만 바꾸어 진행했다. 주가 정상기인 2021·2022·2023 을 각각 단일연도 입력으로 다음 연도에 대한 학습 결과를 내놓았다(즉, 2022 년을 학습하면 2023 년에 대한 예측을 결과로 내놓는다). 결과는 명확했다 — 세 정상기 표본 모두 동일하게 붕괴하였고(그림 7), 다중연도를 학습한 경우만 예측 클래스 분포를 회복했다. 즉, 성능 붕괴의 원인은 시기가 아니라 데이터 규모로 판명되었다. 다시 말해 더 큰, 더 나은 모델이 아니라 더 많은 데이터가 필요한 것이다.
- EXP-G 는 한국 증시의 높은 반도체 비중을 반영해 IT·반도체 부분집합(전체 데이터의 9%)만으로도 전체에 준하는 예측력이 나오는지 시범 확인했다. 그 결과 고전 ML 방식인 TF-IDF 경우 훨씬 적은 데이터로도 비슷하거나 더 뛰어난 성능이 나와서 그 가능성을 확인할 수 있었다. 다만, 딥러닝 방식의 RoBERTa 의 경우에는 성능이 대폭 하락하여 딥러닝 모델에서 학습 데이터셋의 크기의 중요성을 다시 확인할 수 있었다(그림 8).




그림 7. 데이터 크기 vs 시기(EXP-F). 막대 위 숫자=예측에 등장한 클래스 수(1=붕괴). 소표본은 시기와

무관하게 붕괴, 다년(EXP-D)에서 회복.




그림 8. IT section 단독 학습 결과. TF-IDF는 전체 데이터셋 학습과 비슷한 성능을, 반대로 딥러닝 모델은 급격한 성능 저하를 보인다.

2.7.3 정말 신호가 없는가? — 평가 지표를 바꿔 성능 확인 및 학습 epoch 변경

여기가 프로젝트의 본격적인 전환점이다. “모든 방법이 macro-F1에서 무작위 부근 또는 그 이하”이라는 결과를 두고, 사실 그동안의 성능 개선 노력이 결국 음성 결과물(즉, 이 방법은 유용하지 않다는 결론)을 얻는데 그치는 것이 아닌가 걱정이 들 수밖에 없다. 이에 다시 처음으로 돌아가서 학습이 제대로 된 것인지, 그리고 적절한 지표로 평가를 제대로 하고 있는지를 의심했다 — “Attention map이 거의 균일해보이는 현상이 지속되는데 과연 학습이 제대로 된 것인가?”, “macro-F1이 정말 우리가 알고 싶은 ‘방향’을 재고 있는가?”

- EXP-H에서 같은 모델 점수를 이진 방향 정확도·IC(Spearman)·롱숏 백테스트로 재평가하자 그동안의 평가가 뒤집혔다(그림 9). RoBERTa의 IC는 4개 셀(KOSPI/KOSDAQ × h1/h5)·6개 시드 모두에서 양(+)이었고, 특히 KOSPI h5에서 $IC \approx +0.146 \pm 0.026$ 으로 6시드 중 4번 $p < .05$ 였다(신호가 전혀 없다고 가정할 때, 이만한 IC가 우연히 나올 확률이 5% 미만이라는 뜻이다). macro-F1 1위였던 TF-IDF의 방향 IC는 ≈ 0 , wordcount는 음(-)이었다. 분석. 3-class 분류 정확도 지표는 예측이 어려운 flat(0) 클래스를 동일 비중으로 반영해 약한 방향 신호를 가린다(부록 A). 이를 이분 방향성 지표(즉, 횡보를 제외하고 상승 or 하락만 평가)인 IC로 보면 신호가 드러난다 — “적절한 지표 선택이 결론을 만든다”는 것이 본 연구의 1번 메시지다. 즉, 처음 상승-횡보-하락 삼분법으로 모델을 평가 및 해석했던 것이 최적의 선택은 아니었음을 보여준다.

EXP-H 신호 검증 — macro-F1 이 가려진 약신호가 IC 로 검출됨 (다년 test=2024)




그림 9. (좌) 모델별 IC — TF-IDF≈0, wordcount 음, RoBERTa 양. (우) RoBERTa IC의 6시드 분포(빨강=평균). macro-F1이 가려진 약한 양(+)의 방향 신호가 IC로 드러난다.

셀 (cell)	IC 평균 ± 표준편차	양수 / 6시드	유의($p<.05$) / 6
KOSDAQ h1	+0.061 ± 0.022	6 / 6	0 / 6
KOSDAQ h5	+0.068 ± 0.033	6 / 6	0 / 6
KOSPI h1	+0.086 ± 0.038	6 / 6	0 / 6
KOSPI h5	+0.146 ± 0.026	6 / 6	4 / 6

표 7. RoBERTa 방향 IC의 시드 견고성(EXP-H, 다년 6시드). 네 경우 모두 6시드에서 부호는 일관되게 양(+)이었다(6/6). 다만 통계적으로 뚜렷한 건 KOSPI h5뿐이며(6시드 중 4번 유의), 나머지 셋은 유의 수준에는 이르지 못했다. 여러 경우를 동시에 본 점을 감안하면, 부호의 일관성은 분명하나 신호의 세기는 약하다고 보는 것이 타당하다.

이러한 신호를 관찰한 뒤 다음 질문은 이 신호가 “어디서 오는가”였다.

- EXP-I 는 고 confidence 예측일의 적중률이 67%(KOSPI h5)임을 확인하고, attention map 이 어닝·미국 매크로·금리 관련 헤드라인에 집중함을 보였다(그림 10).

Attention map — 헤드라인별 가중치 (가장 집중된 test 사례)




그림 10. 다중연도 학습 attention map. 금융 키워드에 높은 가중치를 보이는 모습이다.

- EXP-J 는 고 confidence 구간만 떼어 보면 이진 정확도 0.54→0.66, IC 0.18→0.21 로 강해짐을 정량화했다(표본 수는 줄어듦).
- EXP-K 는 “제목 대신 본문까지 넣으면?”을 시험했으나 개선이 없었다(IC 0.18→0.09) — 전문 기자가 쓴 기사의 신호의 핵심은 이미 제목에 잘 담겨있기 때문으로 보인다.
- EXP-L 은 BIGKinds 에서 IT_section 을 추가로 병합해 IT 볼륨을 2 배로 늘렸다. TF-IDF 는 성능 유지, RoBERTa 는 단일시드 부호가 흔들려 오히려 성능이 불안정 해졌다. 그 간에 실험에서 학습 자료가 늘어남에 따라 딥러닝 모델이 지속적으로 성능이 불안해지는 모습을 보여왔는데, 이는 학습량이 부족하기 때문으로 보인다. 그동안 학습 장비와 시간의 한계로 인해 타협한 부분(epoch, 데이터 선택 폭)들이 문제로 판단된다. 이에 추후 실험(EXP-O~)에서 학습량을 개선하니 성능이 개선되는 모습을 보였다.
- EXP-M 은 전 실험을 다중 시드로 이진/IC 재평가했다. 그 결과 단일연도로만 학습한 경우 IC 가 $\pm 0.1 \sim 0.3$ 로 부호까지 흔들리는 반면 다중연도를 활용한 경우에는 $+0.146 \pm 0.026$ 으로 안정함을 보였다 — 앞선 EXP-F 에서 내렸던 “원인=데이터 크기” 결론을 통계적으로 확인한 것이다.
- EXP-N 은 순수 IT 분류 단독 데이터셋이 약함을(IC +0.035 vs 본체 +0.146) 보여, EXP-G 의 IT 효과가 “IT 주제” 자체가 아니라 경제·금융 맥락을 동반한 IT(경제적 프레이밍)에서 온다는 점을 분명히 했다. 실제로 데이터셋을 직접 확인한 결과, 주가와 관계가 적은 우주/자연과학 위주의 기사도 IT 카테고리도 포함되어 있는 것을 확인할 수 있었다. 즉, 경제와 무관한 IT/과학 뉴스까지 포함하니 성능이 하락하는 것이다.

2.7.4 신호를 다듬고 일반화하다 — 입력·학습량 개선·단일종목 (EXP-O~X)

신호의 근원을 규명한 뒤에는 “신호를 어떻게 더 잘 뽑는가”, 다시 말해 학습 방법 개선으로 넘어갔다.

- EXP-O 는 data/ 경로에 있는 데이터셋 전체를 아무런 처리 없이 결합해도 RoBERTa 결과가 본체와 완전 동일함을 보였는데, 이는 하드웨어 한계로 제한한 일일 학습 헤드라인 top-30 절단 때문에 추가 데이터셋이 입력에 닿지 않은 것이었다.
- EXP-P 는 그렇다면 실제로 데이터를 더 많이 보면 성능이 좋아지는지 검증해봤다. 그러나 MAX_HEADLINES 를 30→200 으로 키우자 RoBERTa 의 성능이 오히려 악화(macro-F1 0.298→0.181)됐다 — attention pooling 이 희석된 것이다. 이러한 현상은 대폭 늘어난 데이터량에 비해 학습 epoch 이 충분치 않아서 생긴 것으로 판단했다. 이후 정량적 지표인 학습 로그를 분석하여 train loss 가 지속적으로 더 감소할 여지가 있다고 판단했으며, 더불어서 attention map 정성적 분석을 마친 뒤, EXP-T 부터는 시간이 몇 배로 더 소요되더라도 학습량을 늘리기로 결정했다.
- EXP-Q 는 top-30 을 고를 때 최신순으로 고르는 편이 랜덤보다 우월함을(IC +0.146 vs +0.028) 확인했다. 이는 주식 시장에서 정보의 신속한 전달의 중요성을 보여주는 결과로 보인다. 하지만 여전히 성능이 기대값에 못 미치므로 근본적인 해결책은 전체 일일 데이터를 학습하는 것이라는 결론을 내렸다.
- EXP-R 는 모든 방법을 동일 top-30 입력으로 맞춘 공정 비교에서도 지표별 반전이 유지됨을(3-class 는 TF-IDF, IC 는 RoBERTa 우위) 확인했다.
- EXP-S 는 그동안 사용하지 않던 뉴스 식별자의 실제 시간순으로 정보를 정렬하자 단기 신호가 더 강해짐을(KOSPI h1 IC +0.086→+0.134) 보였다. 종합하면 RoBERTa 에는 최신·실시간순 입력이 최적이다.
- EXP-T 는 앞선 여러 실험의 내용을 종합하여 그동안의 학습 충분성을 점검하고 그동안 진행한 4 epoch 이 커진 데이터셋에 부족했고, 10 epoch 학습 시 0.298→0.339 로 성능이 더 오르는 것을 확인했다. 이에 따라 이후 진행할 최종 삼성전자 단일종목 실험은 30 epoch 으로 충분히 학습했다.

이후 실험에서는 그동안 하드웨어 한계로 인해 타협했던 batch size와 최대 헤드라인 개수를 개선하고자 하였다. 전체 일일 헤드라인을 적은 자원에서 제대로 활용하기 위해서 전체 종합 지수에 적용하지 않고, 단일 종목으로 범위를 좁혀서 국소 적용해 보았다. 그 결과는 성공적이었다.

- EXP-V 는 삼성전자의 전체 헤드라인을 30 epoch 으로 충분히 학습한 최종 모델이다. BigKinds 에서 삼성전자를 키워드로, 기존 3 개 신문사(조선일보, 한겨레, 한국경제)가 아닌 단일 신문사(한국경제)를 선택하여 데이터셋을 구성했다. 이를 통해 하루 내에 전체 학습이 원활히 완료되도록 하였다. 학습 결과는 2024 년 h5 방향 적중률 0.59 로 무작위(0.50)를 상회하는, 본 연구에서 가장 뚜렷한 양(+)의 방향 신호를 얻었다. 다만 2024 년은 주가가 내린 날이 더 많았던 해라서, 단순히 ‘항상 내린다’라고만 찍어도 약 0.57 은 맞는다. 즉 모델의 0.59 는 이 기준을 근소하게 웃도는 수준으로, 의미 있는 신호이긴 하나 그 폭이 크지는 않다.
- EXP-W 는 앞선 EXP-V 모델이 2025 년에는 왜 유독 약해지는지 분석했다. 원인은 신호 부재가 아니라 데이터 자체의 분포 이동(distribution shift)이었다. (그림 11): 2025 년 삼성전자는 역사상 유례없는 +124.5% 폭등으로 전체 영업일 중 h5 상승일이 62%에 달했는데, 지난 수십년간 일명 ‘박스피’로 불렸던 2021~2023 년 종가로 학습한 모델은 상승을 단 24%만 예측해 주식 시장의 전체 흐름 변화를 따라가지 못했다. 검증을 위해 21~23 년 자료를 학습하고 2024 년과 2025 년을 각각 예측하였다. 그 결과 24 년(정상기)의 양(+) 신호는 ‘항상 상승’ 기준을 상회하며 잔존했지만, 반대로 2025 년의 전례없는 상승을 제대로 예측하진 못하였다. 이는 ML 의 고질적인 한계로, AI 는 학습하지 않거나 이례적인 데이터(outlier)에 취약한 것을 확인할 수 있었다.




그림 11. (좌) 삼성전자 연수익률 — 2025 +124% 이례적 상승. (우) 모델은 균형 예측(파랑), 2025 실재는 상승 풀림(주황) → 분포 이동으로 추종 실패. 반면 정상기(2024)에서는 적응이 무작위를 상회.

연도	연수익률	h5 상승일 비율	모델 방향적중(h5)	‘항상 상승’
2023	+41.4%	53%	—	—
2024 (정상)	-33.2%	43%	0.59	0.43
2025 (폭등)	+124.5%	62%	0.44	0.62

표 8. 삼성전자 연도별 레짐과 모델 방향 적중(EXP-V/W). 정상기 2024에서는 모델이 무작위·‘항상 상승’을 모두 상회.

2.7.5 향후 과제: 진행 중인 최종 실험 (EXP-U)

- EXP-P(전체 헤드라인 학습)와 EXP-T(4 epoch 부족)를 충분 학습·전량 입력 조건에서 동시에 재검증하는 마지막 통제 실험으로, 다년 데이터를 top-30 절단 없이 전량(MAX_HEADLINES=1059) 넣고 이진·30 epoch 으로 재학습한다(gradient checkpointing 으로 24GB 내 학습, batch=2). 설계는 확정·착수했으며 학습 장비의 한계 및 시간 문제로 인해 본 보고서에는 결과를 포함하지 못했다. 다만 코드는 남겨두고 시험 삼아서 1 epoch 이 돌아가는 것을 확인했다. 추후 장시간 사용이 가능한 고성능 서버에서는 원활히 학습이 돌아갈 것으로 기대한다. AI 학습에서 GPU 의 중요성을 체감할 수 있는 대목이다.

3. 결론

뉴스 헤드라인의 주가 방향 예측력은 약하지만 분명 실재한다. 본 연구의 성과는 네 가지다.

- 적절한 평가 지표가 타당한 결론을 만든다 — macro-F1로는 가려졌던 신호가 IC로 드러났다(RoBERTa KOSPI h5 IC $\approx +0.15$, 6시드 안정).
- 삼성전자 단일 종목 전체 학습 모델은 정상기(2024)에서 방향 적중 0.59로 무작위 기준을 상회하는 약한 방향 신호를 관측했다(다만 하락이 우세했던 해라 ‘항상 내린다’ 기준 약 0.57은 근소하게 웃도는 수준이다).
- 데이터셋이 부족한 경우 학습 모델 자체 성능에 관계없이 성능이 붕괴하는 것을 관찰할 수 있었다. 이를 통해 학습 데이터의 중요성을 확인할 수 있었다.
- RoBERTa에는 최신·실시간순 입력이 최적이고 신호는 일부 경제적 어휘에 몰려있는 것을 확인했다. 다만 신호의 폭이 작아 룬샷 백테스트(알고리즘 주식 시뮬레이션)에서는 결정적인 모습을 보이지는 않았다. 즉, 신호 탐지는 되나 거래에 반드시 참고할 자료는 아니다 — 앞서 서론에서 언급한 weak form 시장 효율성과 정합하는, 학술적으로 의미 있는 음·약신호의 경계 사례다.

4. 참여후기

본 보고서를 처음 작성할 때 RoBERTa가 단어 기반 baseline에 지는 결과를 보고 프로젝트가 유의미한 결과를 갖지 못할 수도 있다는 두려움에 휩싸였다. 유의미한 결과를 내야 한다는 압박감에 많은 실험을 진행하며 그 원인을 최대한 파악하고자 했다. 그러다 “macro-F1이 정말 내가 알고 싶은 ‘방향’을 재고 있나?”를 의심하고 지표를 IC로 바꾸자 가려져 있던 약한 신호가 드러났다. 같은 데이터·같은 모델인데 평가 지표 하나로 결론이 뒤집히는 경험은, 이 수업이 강조한 ‘문제 정의’와 ‘해석’의 중요성을 가장 또렷하게 체감하게 해 주었다.

24개의 실험을 하루하루 이어 붙이는 과정도 큰 배움이였다. 한 실험의 실패가 다음 실험의 가설이 되고(붕괴 → 동결 → 데이터 확대 → 데이터 크기 통제), 그 연쇄가 결국 “원인은 데이터 규모와 그 학습량”이라는 결론으로 수렴하는 흐름을 직접 설계하면서, 좋은 연구는 한 번의 성공이 아니라 잘 설계된 실패의 연속이라는 것을 배웠다. 통계적 엄밀성을 지키려 IC의 유의성을 시드별로 신중히 보고하고, 단일종목 결과를 완전 held-out으로 공정한 비교를 통해 한 번 더 확인한 점도 스스로 만족스럽다.

본 연구를 통해 실제 주식에 사용할 수 있는 모델을 개발하는 데는 성공했다고 말하기 어렵다. 결국 앞선 모든 다른 연구가 도달한 결론과 같았다. “주식 시장은 한 치 앞도 알 수 없다.” 본 연구는 ML 학습 뿐만 아니라 투자에 대한 교훈을 준다. 딥러닝 모델을 학습시키듯이 우리는 주식을 공부하고 정보를 구하며 주식을 사고 판다. 그러나 때로는 우리 사회가 더 발전할 것이라는 희망을 갖고 그저 우직하게 항상 갖고 있는 것(즉, ‘항상 상승’, 일명 ‘존버’)이 해답일 때도 있다. 본 연구처럼 어렵게 어렵게 AI 모델을 학습시켜 주식을 매매할 때보다 그저 장기간 보유하고 있는 경우가 수익률이 훨씬 좋았다. 이것이 어쩌면 이 연구가 주는 진정한 교훈이 아닐까? “투자란 미래에 기대되는 수익을 위하여 현재소비를 포기하는 것을 의미한다.” [13] 우리는 투자를 통해 다음 두 가지 보상을 기대한다: “시간적 보상”과 “위험에 대한 보상”이다. 이때 투자하는 시간이 짧으면 같은 수익을 받기 위해서는 일반적으로 그만큼의 “위험에 대한 보상”을 늘려야 한다. 자본주의의 꽃이자 전쟁의 최전선인 주식 시장에서, “시간에 대한 보상”을 진득하게 기다리며 “위험을 최소화”하는 것이 이 전쟁에서 살아남기 위한 바람직한 투자 방법이라고 생각한다.

Gen-AI를 코드 작성과 실험 로그 정리에 적극 활용했지만, 어떤 지표로 평가할지·어떤 통제 실험으로 가설을 기각할지·결과를 어떻게 해석할지는 결국 스스로 판단해야 했다. AI는 손을 빠르게 해 주는 도구였고 문제의식과 해석은 내 몫이라는 균형을 익혔다. 개선 제안을 하나 남기자면, 본 기말고사 대체 프로젝트가 공통의 주제가 없는, 자유 주제라는 끝이 안 보이는 마라톤과 같은 느낌이 들었다. 완벽주의 성향이 강해서인지 데이터셋을 구축하고 구현하며 실험하는 과정이 개인적으로 꽤 고되고 좌절감의 연속이었다. 불안한 자유보다는 예상 가능한 틀에 박힌 삶을 좋아하는 평범한 소시민, 한낱 범부로서, 어떤 공통 과제에 대하여 상대평가식으로 진행되는 것이 개인적으로는 덜 피곤했을 것 같다. 한 학기 동안 좋은 수업에 감사드린다.

긴 글 읽어주셔서 감사합니다.

[참고문헌]

참고문헌 및 출처는 APA 7판을 변형해 명시했다. 본문의 대괄호 번호 [n]은 아래 목록 번호와 1:1로 대응한다. 목록은 카테고리(A~E)별로 묶고, 번호를 이어 매겼다(카테고리 내부는 저자 알파벳순).

A. 핵심 모델(딥러닝)

1. Bahdanau, D., Cho, K., & Bengio, Y. (2015). Neural machine translation by jointly learning to align and translate. 3rd International Conference on Learning Representations (ICLR).

<https://doi.org/10.48550/arXiv.1409.0473>

2. Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., Levy, O., Lewis, M., Zettlemoyer, L., & Stoyanov, V. (2019). RoBERTa: A robustly optimized BERT pretraining approach (arXiv:1907.11692). arXiv. <https://doi.org/10.48550/arXiv.1907.11692>
3. Park, S., Moon, J., Kim, S., Cho, W. I., Han, J. Y., Park, J., Song, C., Kim, J., Song, Y., Oh, T., Lee, J., Oh, J., Lyu, S., Jeong, Y., Lee, I., Seo, S., Lee, D., ... Cho, K. (2021). KLUE: Korean language understanding evaluation (arXiv:2105.09680). arXiv. <https://doi.org/10.48550/arXiv.2105.09680>
4. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. Advances in Neural Information Processing Systems, 30, 5998 – 6008.

B. Baseline 방법

5. Loughran, T., & McDonald, B. (2011). When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks. The Journal of Finance, 66(1), 35 – 65. <https://doi.org/10.1111/j.1540-6261.2010.01625.x>
6. Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825 – 2830.

C. 평가·이론

7. Fama, E. F. (1970). Efficient capital markets: A review of theory and empirical work. The Journal of Finance, 25(2), 383 – 417. <https://doi.org/10.2307/2325486>
8. Spearman, C. (1904). The proof and measurement of association between two things. The American Journal of Psychology, 15(1), 72 – 101. <https://doi.org/10.2307/1412159>

D. 데이터·도구

9. FinanceData. (n.d.). FinanceDataReader [Computer software]. GitHub. <https://github.com/FinanceData/FinanceDataReader>
10. Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., Cistac, P., Rault, T., Louf, R., Funtowicz, M., Davison, J., Shleifer, S., von Platen, P., Ma, C., Jernite, Y., Plu, J., Xu, C., Le Scao, T., Gugger, S., ... Rush, A. M. (2020). Transformers: State-of-the-art natural language processing. Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations, 38 – 45. <https://doi.org/10.18653/v1/2020.emnlp-demos.6>
11. 한국언론진흥재단. (n.d.). BIGKinds: 뉴스 빅데이터 분석 서비스 [Data set]. <https://www.bigkinds.or.kr/>

E. 기타 자료

12. 상장사 주주 1456만명으로 사상 최대... 삼성전자 100만명 이탈. (2026, 3월 18일). 조선비즈. https://biz.chosun.com/stock/stock_general/2026/03/18/IHHEREBOGNFJBjVL4FSRKSP76Q/
13. 감형규, 신용재, 이익택, 김영규. (2022). 증권투자론 (제5판). 율곡출판사.

부록 (Appendix): A~D - 통계 용어·기법 설명

본문에 등장한 평가 지표와 기법을 비전공자도 따라올 수 있도록 풀어서 정리했다.

부록 A. Macro-F1 (거시 평균 F1)

분류 성능 지표다. 한 클래스 c 에 대해 정밀도(precision) $P_c = TP/(TP+FP)$, 재현율(recall) $R_c = TP/(TP+FN)$ 이며, $F1_c = 2 \cdot P_c \cdot R_c / (P_c + R_c)$ 은 둘의 조화평균이다(TP =참양성, FP =거짓양성, FN =거짓음성). $macro-F1 = (1/C) \cdot \sum_c F1_c$ 로, 클래스별 F1을 표본 수와 무관하게 동일 비중으로 평균한다. 3-class $\{-1, 0, +1\}$ 에서 '0(횡보)' 클래스는 임계 부근이라 예측이 본질적으로 어렵다. macro 평균은 이 어려운 클래스를 $\pm$ 클래스와 똑같이 반영하므로, 방향($\pm$) 신호가 있어도 0 클래스의 낮은 F1이 전체를 끌어내려 "무작위처럼" 보이게 한다. 본 연구가 macro-F1만으로 신호를 놓칠 뻔한 이유가 여기 있다. 무작위 기준선은 균형 3-class에서 약 0.333이다.

부록 B. IC — Information Coefficient (정보계수)

퀀트 금융에서 예측의 질을 재는 표준 지표로, 모델 점수 s 와 실제 수익 r 의 Spearman 순위상관(rank correlation) [8]이다. 범위는 $-1 \sim +1$ 이고 무작위 기준선은 0이다(이진 정확도의 기준선 0.5와 다름에 주의 — 부록 C 참고). 실무에서 단일 팩터의 $|IC|$ 0.05~0.10도 유의미한 수준으로 본다.

이진 정확도와 주요 차이점: IC는 점수 분포 전체의 순위 정렬을, 이진 정확도는 한 임계점에서의 부호 일치를 쟀다. 따라서 $IC > 0$ 이라고 이진 정확도 > 0.5 가 보장되지는 않는다. 예를 들어 본 연구에서 KOSDAQ h5는 IC가 양(+)이면서도 이진 정확도는 0.5 미만이었는데, 이는 모순이 아니라 두 지표가 다른 것을 재기 때문이다.

부록 C. 롱숏 백테스트와 통계적 유의성

신호가 "통계적으로 보이는 것"과 "돈이 되는 것"은 다르다. 롱숏 백테스트(long-short backtest)는 모델 점수 상위 종목·일자를 매수(long), 하위를 매도(short)하는 가상 포트폴리오의 평균 forward return을 계산한다. 즉, "주식 거래 알고리즘으로 과거 특정 기간에서 매매 시뮬레이션을 하는 것"이다. IC가 양(+)이어도 신호의 분산 대비 평균수익이 작으면(본 연구는 IC 분산 $\sim 2\%$) 백테스트 수익이 통계적으로 유의하지 않을 수 있다는 점이다. 게다가 여기엔 거래비용·슬리피지 등이 반영되지 않았다. 그래서 본 연구는 "신호는 탐지되나 거래 가능한 수준은 아니다"로 결론지었고, 이는 weak form 시장 효율성 가설과 정합한다.

부록 D. 보조 개념: 라벨링·시간 순 분할·누설 봉쇄

ternary 라벨링: 수익 r_h 가 임계 ε_h 를 넘으면 $+1$, $-\varepsilon_h$ 미만이면 -1 , 사이면 0(횡보)으로 둔다. $\varepsilon_h = 0.3 \cdot \sigma_h$ 이며 σ_h 는 "의미 있는 움직임"의 척도다. 이 σ_h 를 train 구간에서만 추정해 val·test에 적용하는 것이 미래 정보 누설 방지의 핵심이다.

Temporal split(시간 순 분할). 데이터를 무작위가 아니라 시간축으로 train→val→test로 나눠, 과거로 학습하고 미래로 평가한다(실거래 상황과 동일). 통상적인 ML 학습에서는 일반적으로 데이터셋을 무작위 셔플을 진행하지만, 주식 거래의 경우 데이터의 순서 또한 유의미한 정보를 제공하므로 시간 순을 보존해야 한다.

Look-ahead 봉쇄: 뉴스일 D 를 다음 거래일 $T(T>D)$ 로 매핑하고 입력은 T 장 시작 이전 발행분만 사용해, 미래 정보가 입력으로 새는 것을 코드 수준에서 차단한다(코드 1).

부록 (Appendix): E~G: 세 비교 방법의 입력 - 처리 - 출력 명세

본 부록은 본 연구가 비교한 세 방법을 입력(input) → 처리 방식(processing) → 출력(output) 구조로 정리한다. 본 실험에서 사용한 모델은 다음 세 가지 모델이다: ① wordcount(비-ML 규칙 기반) → ② TF-IDF + Logistic Regression(고전적 ML) → ③ RoBERTa(딥러닝). 모든 방법은 동일한 거래일 단위 데이터·동일한 라벨·동일한 시간 순 분할을 공유하며, 입력은 모두 “거래일 t에 대응하는 헤드라인 묶음”에서 출발한다.

부록 E. wordcount — 비-ML 렉시콘 단어개수

개요: 규칙 기반(rule-based)의 알고리즘은 성능의 하한선(lower bound)으로 생각했다. Wordcount 알고리즘은 ML 기반 모델과 다르게 학습되는 파라미터가 없다. 그저 단순히 “긍정 단어가 많으면 오르고 부정 단어가 많으면 내린다”는 직관을 그대로 규칙화한 것이다.

입력 (input)

- 거래일 t의 헤드라인 리스트(최신순; 긍정 비교 시 최신 top-N)를 공백으로 이어 붙인 하루치 문자열 1개.
- 수작업으로 만든 금융 방향성 시드 사전 — 긍정 30 단어(상승·급등·강세·호재·반등 ...), 부정 30 단어(하락·급락·악세·악재·침체 ...).

처리 방식 (processing)

- (1) net score 계산 — 하루 문자열에서 긍정 시드 출현수에서 부정 시드 출현수를 뺀다(부분문자열 매칭이라 ‘상승/상승세/상승했다’를 모두 센다).
- (2) 경계 결정 — 3-class 경계 τ_{lo} , τ_{hi} 를 train 라벨 분포에 맞추어 비율대로 정한다(학습이 아니라 train의 클래스 비율만 차용).
- (3) 예측 — score가 τ_{lo} 미만이면 -1, τ_{hi} 초과면 +1, 사이면 0.

```
net =  $\sum$  doc.count(긍정시드) -  $\sum$  doc.count(부정시드)    # 부분문자열 매칭
 $\tau_{lo}$  = quantile(train_score, p_down)                    # train 분위수 경계만 차용
 $\tau_{hi}$  = quantile(train_score, p_down + p_flat)
 $\hat{y}$  = -1 if net <  $\tau_{lo}$  else (+1 if net >  $\tau_{hi}$  else 0)
```

코드 A. wordcount 처리 — 학습 파라미터 없이 train 데이터 비율대로 경계만 맞춘다.

출력 (output)

- 거래일별 방향 예측 라벨 $\hat{y} \in \{-1, 0, +1\}$. (IC 평가 시에는 net score를 연속 점수로 사용.)

특징·한계: 결정적이라 시드와 무관하다. 다만 형태소 분석 없이 부분문자열만 보므로 부정 결합(‘상승하지 못’)을 구분하지 못한다. 본 연구 결과, wordcount의 IC는 오히려 음(-)으로 나와 약한 역추세(과민 반응) 신호를 보였다. 즉, 주식 거래에 참고하기에는 유용하지 않다.

부록 F. TF-IDF + Logistic Regression — 고전적 ML baseline

개요: TF-IDF는 최근 각광받는 신경망 기반의 딥러닝(Deep Learning)과 대비되는 고전적 머신러닝(classical ML)으로, 본 연구에서 딥러닝 모델이 뛰어넘어야 할 baseline으로 잡았다. TF-IDF는 텍스트를 숫자 벡터로 바꾸는 특징 추출(feature extraction) 기법이고, 예측·학습은 그 위의 Logistic Regression(로지스틱 회귀)이 담당한다. 둘을 합친 파이프라인 전체가 ML 분류기다.

입력 (input)

- 거래일 t 의 헤드라인 리스트를 공백으로 이어 붙인 하루치 document 1개(공정 비교 시 최신 top-N).
horizon × 지수 = 8개 셀 각각을 독립 모델로 학습.

처리 방식 (processing)

(1) 벡터화(TF-IDF) — 단어 빈도(TF, term frequency)에 역문서빈도(IDF, inverse document frequency)를 곱해, ‘이 문서엔 자주 나오지만 전체엔 드문’ 단어에 높은 가중치를 준다. 어휘(vocabulary)는 train에서만 fit하고 test는 변환(transform)만 한다(누설 방지).

(2) 분류(Logistic Regression) — TF-IDF 희소 벡터를 입력으로 3-class 확률을 학습한다(class_weight=balanced로 불균형 보정). 결정적(시드 무관)이다.

```
vec = TfidfVectorizer(min_df=2, max_features=20000, ngram_range=(1,1))
Xtr = vec.fit_transform(train_docs) # 어휘는 train에서만 학습
Xte = vec.transform(test_docs)      # test는 변환만(누설 방지)
clf = LogisticRegression(max_iter=2000, C=1.0, class_weight='balanced')
clf.fit(Xtr, ytr); pred = clf.predict(Xte)
```

코드 B. TF-IDF 벡터화(train fit) + Logistic Regression 분류.

출력 (output)

- 거래일별 3-class 예측 라벨·확률. 8셀(horizon × 지수) accuracy·macro-F1. (IC 평가 시 +1 클래스 확률을 방향 점수로 사용.)

특징: 관련성 필터로 차원이 줄면 크게 향상되고, 많은 입력을 선호한다. 본 연구에서 macro-F1 최강이었으나, 방향 IC는 ≈ 0 이라 분류 정확도와 방향성이 분리되는 모습을 제공했다.

부록 G. RoBERTa — 딥러닝(deep learning) 주 모델

개요: 본 연구의 주 모델로, 한국어 사전학습 언어모델 klue/roberta-base를 미세조정(fine-tuning)했다. 앞의 두 비교 방법(wordcount·TF-IDF)이 단어의 개수나 빈도만 보는 데 비해, RoBERTa는 문장의 의미를 숫자로 이해하고, 하루치 여러 헤드라인 중 “어떤 제목이 중요한지”를 스스로 학습한다(learnable query attention pooling, § 2.4).

입력 (input)

- 거래일 t 에 대응하는 헤드라인 묶음(최신순 top-30). 각 헤드라인은 최대 64토큰(MAX_LENGTH)으로 잘라 인코더에 개별 입력한다.

처리 방식 (processing) — 수식 풀어 읽기

하루에 헤드라인이 여러 개 쏟아진다. 핵심 질문은 “이 여러 제목을 어떻게 하루 한 개의 요약으로 합치느냐”

이고, 모델은 이를 네 단계로 푼다. 각 단계의 기호(notation)와 직관은 다음과 같다.

(1단계) 헤드라인 → 의미 벡터: $e_i = \text{encoder}(\text{headline}_i)$

- $e_i \in \mathbb{R}^{768}$ 은 i 번째 제목을 768개의 숫자로 바꾼 것이다. 즉, 문장 하나를 768칸짜리 좌표로 찍는 것이다. 비슷한 의미의 제목은 좌표도 서로 가깝게 모인다. 컴퓨터는 글자를 직접 다루지 못하므로, 의미를 숫자 위치로 번역한다고 보면 된다.

(2단계) 중요도 매기기(attention): $\alpha_i = \text{softmax}(q \cdot e_i)$

- $q \in \mathbb{R}^{768}$ 는 학습되는 질의 벡터(query) — 모델이 훈련을 통해 갖게 된 “무엇이 중요한지 보는 잣대”다.

- $q \cdot e_i$ 는 두 벡터의 내적(dot product)으로, 둘이 얼마나 같은 방향을 가리키는지를 하나의 점수로 만든다. 제목이 모델의 잣대와 잘 맞을수록 점수가 크다.

- softmax 는 이 점수들을 합이 1이 되는 비율로 바꾼다($\alpha_i \geq 0, \sum_i \alpha_i = 1$). 즉, 그날 제목들에 “주목도 100%를 몇 %씩 나눠 줄지”를 정하는 단계다. 다시 말해, q 와 잘 맞는 제목이 더 큰 몫(α_i)을 가져간다.

(3단계) 하루 한 줄로 요약: $d_t = \sum_i \alpha_i \cdot e_i$

- 각 제목 벡터 e_i 에 그 주목도 α_i 를 곱해 더한 가중평균(weighted average)이다. 즉, 중요한 제목은 크게, 사소한 제목은 작게 반영해 하루치를 한 개의 요약 좌표 d_t 로 압축한다. 단순 평균(모두 똑같이 반영)과 달리, 중요하다고 학습한 제목의 비중이 커진다.

(4단계) 방향 예측: $\hat{y}(h) = \text{softmax}(W_h \cdot d_t + b_h)$

- 요약 d_t 를 horizon h 별 분류기(W_h, b_h)에 넣어 상승/횡보/하락 확률을 산출한다. $h \in \{1, 5, 21, 252\}$ 를 한 번에 예측한다(multi-task). 즉, 하루 요약과 보고 “1.5·21·252거래일 뒤에 오를지/그대로일지/내릴지”를 각각 확률로 답하는 마지막 단계다.

```
e = encoder(headlines[:, 0, :])      # 1단계: 각 제목 -> 768칸 의미벡터
a = softmax(e @ q)                   # 2단계: 잣대 q와의 내적 -> 주목도 비율(합=1)
d_t = (a[:, None] * e).sum(0) + index_emb # 3단계: 주목도로 가중평균 -> 하루 요약
yh = softmax(W[h] @ d_t + b[h])      # 4단계: 요약 -> horizon h의 상승/횡보/하락 확률
```

코드 C. attention pooling의 추론 흐름(수식 1과 동일). 주석의 1~4단계가 위 설명과 대응한다.

출력 (output)

- 거래일별·horizon별 상승/횡보/하락 예측 라벨·확률. (IC 평가 시 +1 클래스 확률을 방향 점수로 사용.)
- 부수적으로 주목도 α_i 를 뽑아 “모델이 주목한 제목”을 시각화할 수 있다(그림 2~5·10).

특징·한계: 딥러닝 모델 특성상 의미를 직접 학습하므로 데이터의 양에 민감하다. 즉, 데이터셋이 충분히 커야 한다. — 표본이 작으면 단일클래스 붕괴 (§ 2.7.1)가, 충분히 크면 신호 포착이 일어난다. 또한 주목도 (α_i)로 판단 근거를 들여다볼 수 있다는 점이 규칙·통계 기반 방법과 구별되는 강점이다.